

Inteligencia Artificial

Búsqueda adversarial y Árboles de juegos

Índice

3. Espacio de estados y búsqueda

3.1 Métodos de búsqueda no informados (Uninformed Search Methods):

- Búsqueda en anchura (Breadth-First Search)
- Búsqueda en profundidad (Depth-First Search)
- British Museum
- Búsqueda de coste uniforme (Uniform-Cost Search)

3.2 Métodos de búsqueda informados (Informed Search Methods):


- Heurísticos
- Búsqueda voraz (Greedy Search)
- Búsqueda A* (A* or A star search)
- Grafos AND / OR

3.3 Búsqueda adversarial

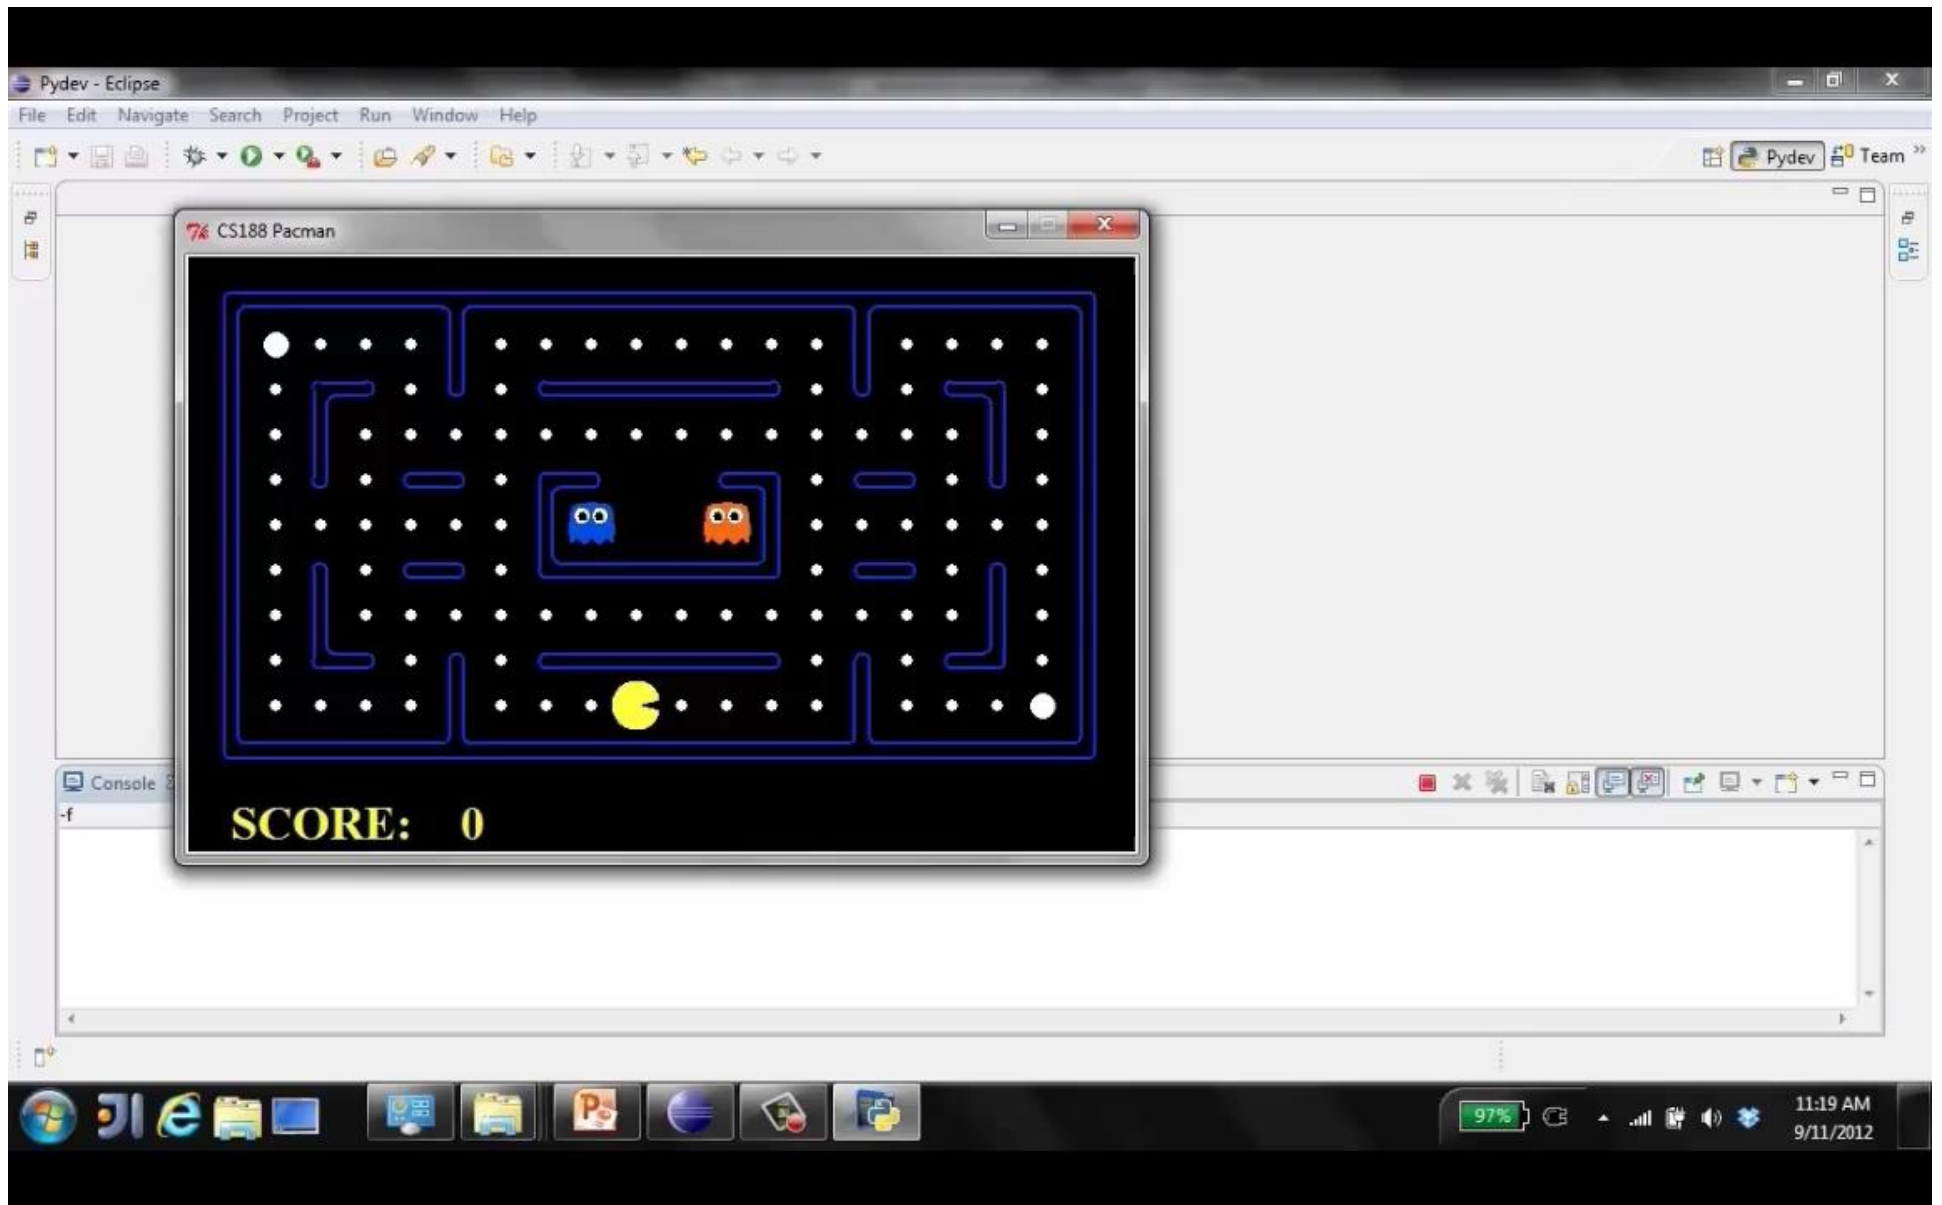
- Minimax
- Alfa-beta
- Expectimax

Estado del arte en algunos juegos


- **Damas 1989 - 2007:** Primer campeón automático (Chinook 1990 **campeonato mundial**) acabó con el reinado de 40 años del campeón Marion Tinsley. En ¿2007?: **¡Damas resueltas!**
- **Ajedrez 1997:** Deep Blue derrota al campeón Gary Kasparov en un torneo de 5 partidas. Deep Blue examinó **200M posiciones por segundo**. Los programas actuales son todavía mejores.
- **Go 2016:** Los campeones humanos empiezan a ser superados por las máquinas **AlphaGO**. En GO, **b > 300 ramificaciones!** Los programas clásicos usan bases de conocimiento de patrones, pero recientes avances usan métodos de expansión Monte Carlo, Redes Neuronales Profundas (**AlphaZero?** ...)
- **Pacman**



Video Demo Mystery Pacman




Juegos Adversariales



Tipos de juegos

- ¡Hay muchas clases de juegos!
- A **tener en cuenta**:
 - ¿Determinístico o estocástico?
 - ¿Uno, dos o más jugadores?
 - ¿Suma cero?
 - ¿Información perfecta (podemos ver el estado)?
- Queremos algoritmos para calcular una estrategia (política o policy) **que recomiende un movimiento desde cada estado**




Juegos determinísticos



➤ Muchas formalizaciones posibles, una es:

- Estados: S (inicio en s_0)
- Jugadores: $P=\{1\dots N\}$ (normalmente a turnos)
- Acciones: A
- Función de transición: $S \times A \rightarrow S$
- Test de terminación (estado objetivo o final): $S \rightarrow \{t, f\}$
- **Función de utilidad** para estados terminales (**borde**)

➤ La solución para un jugador es una política: $S \rightarrow A$



Juegos de suma cero




➤ Juegos de suma cero

- Los agentes tienen utilidades opuestas (valores)
- Podemos pensar en un único valor que uno maximiza y el otro minimiza
- **Adversarial, competición pura**


➤ Juegos generales

- Los agentes tienen utilidades independientes (valores)
- **Cooperación, competición, y más, todo es posible**

Búsqueda Adversarial: suma cero



Árboles con un solo Agente




Valor de un estado

Valor de un estado:
El mejor resultado
(**utility**) desde ese
estado


Estados no terminales:

$$V(s) = \max_{s' \in \text{children}(s)} V(s')$$



Estados terminales:
 $V(s) = \text{conocido}$

Árboles de estados Adversariales: 1 adversario




Valores Minimax: 1 adversario

Estados bajo el control del agente:

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

Estados bajo el control del oponente:


$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$



Estados terminales:

$$V(s) = \text{conocido}$$

Árbol de juegos de Tic-Tac-Toe



Búsqueda Adversarial (Minimax): 1 adversario


➤ Juegos **determinísticos, de suma cero**:

- Tic-tac-toe, ajedrez, damas
- Un jugador maximiza el resultado
- El otro minimiza el resultado

➤ Búsqueda **Minimax**:

- Árbol de búsqueda en un espacio de estados
- Los jugadores alternan turnos
- Se calcula el **valor minimax** de cada estado: el máximo resultado (**utility**) posible, contra un adversario racional (**óptimo**)

Valores Minimax:
calculados **recursivamente**



Valores terminales

Implementación de Minimax


```
def max-value(state):
```

```
    initialize v =  $-\infty$ 
```

```
    for each successor of state:
```

```
        v = max(v, min-value(successor))
```

```
    return v
```



```
def min-value(state):
```

```
    initialize v =  $+\infty$ 
```

```
    for each successor of state:
```

```
        v = min(v, max-value(successor))
```

```
    return v
```

$$V(s) = \max_{s' \in \text{successors}(s)} V(s')$$

El valor **v** empieza con $-\infty$
y va aumentando

$$V(s') = \min_{s \in \text{successors}(s')} V(s)$$

El valor **v** empieza con $+\infty$
y va disminuyendo

Implementación de Minimax (Dispatch)

def value(state):

if the state is a terminal state: return the state's utility

if the next agent is **MAX**: return **max-value(state)**

if the next agent is **MIN**: return **min-value(state)**

def max-value(state):

initialize $v = -\infty$

for each successor of state:

$v = \max(v,$
 $\text{value}(\text{successor})$)

return v

def min-value(state):

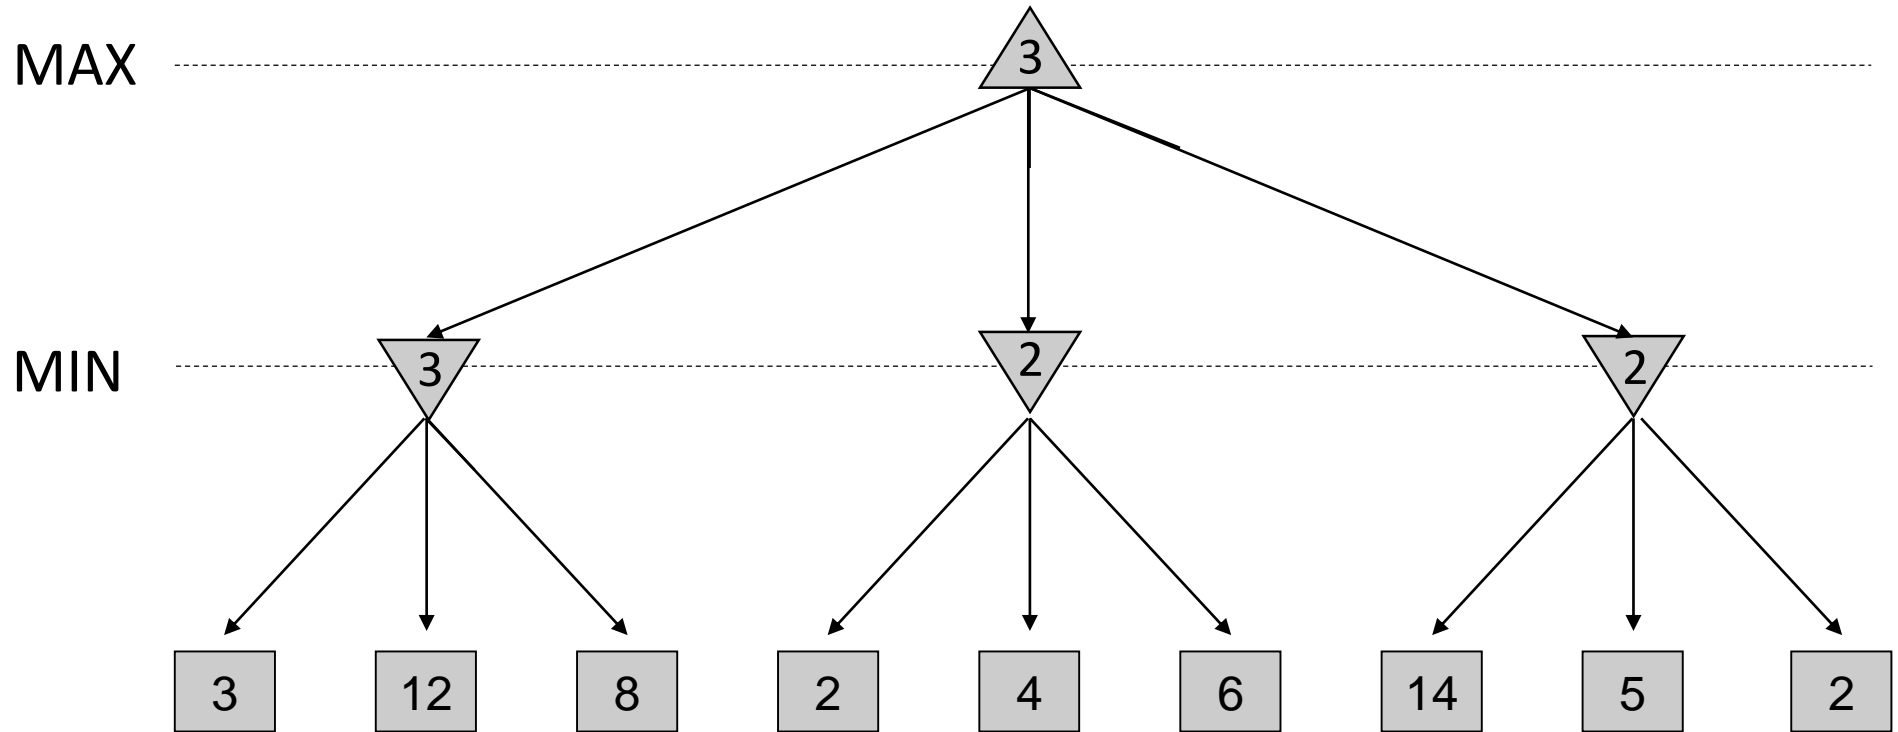
initialize $v = +\infty$

for each successor of state:


$v = \min(v,$
 $\text{value}(\text{successor})$)

return v




Ejemplo de Minimax



Árbol de una aplicación del mini-max

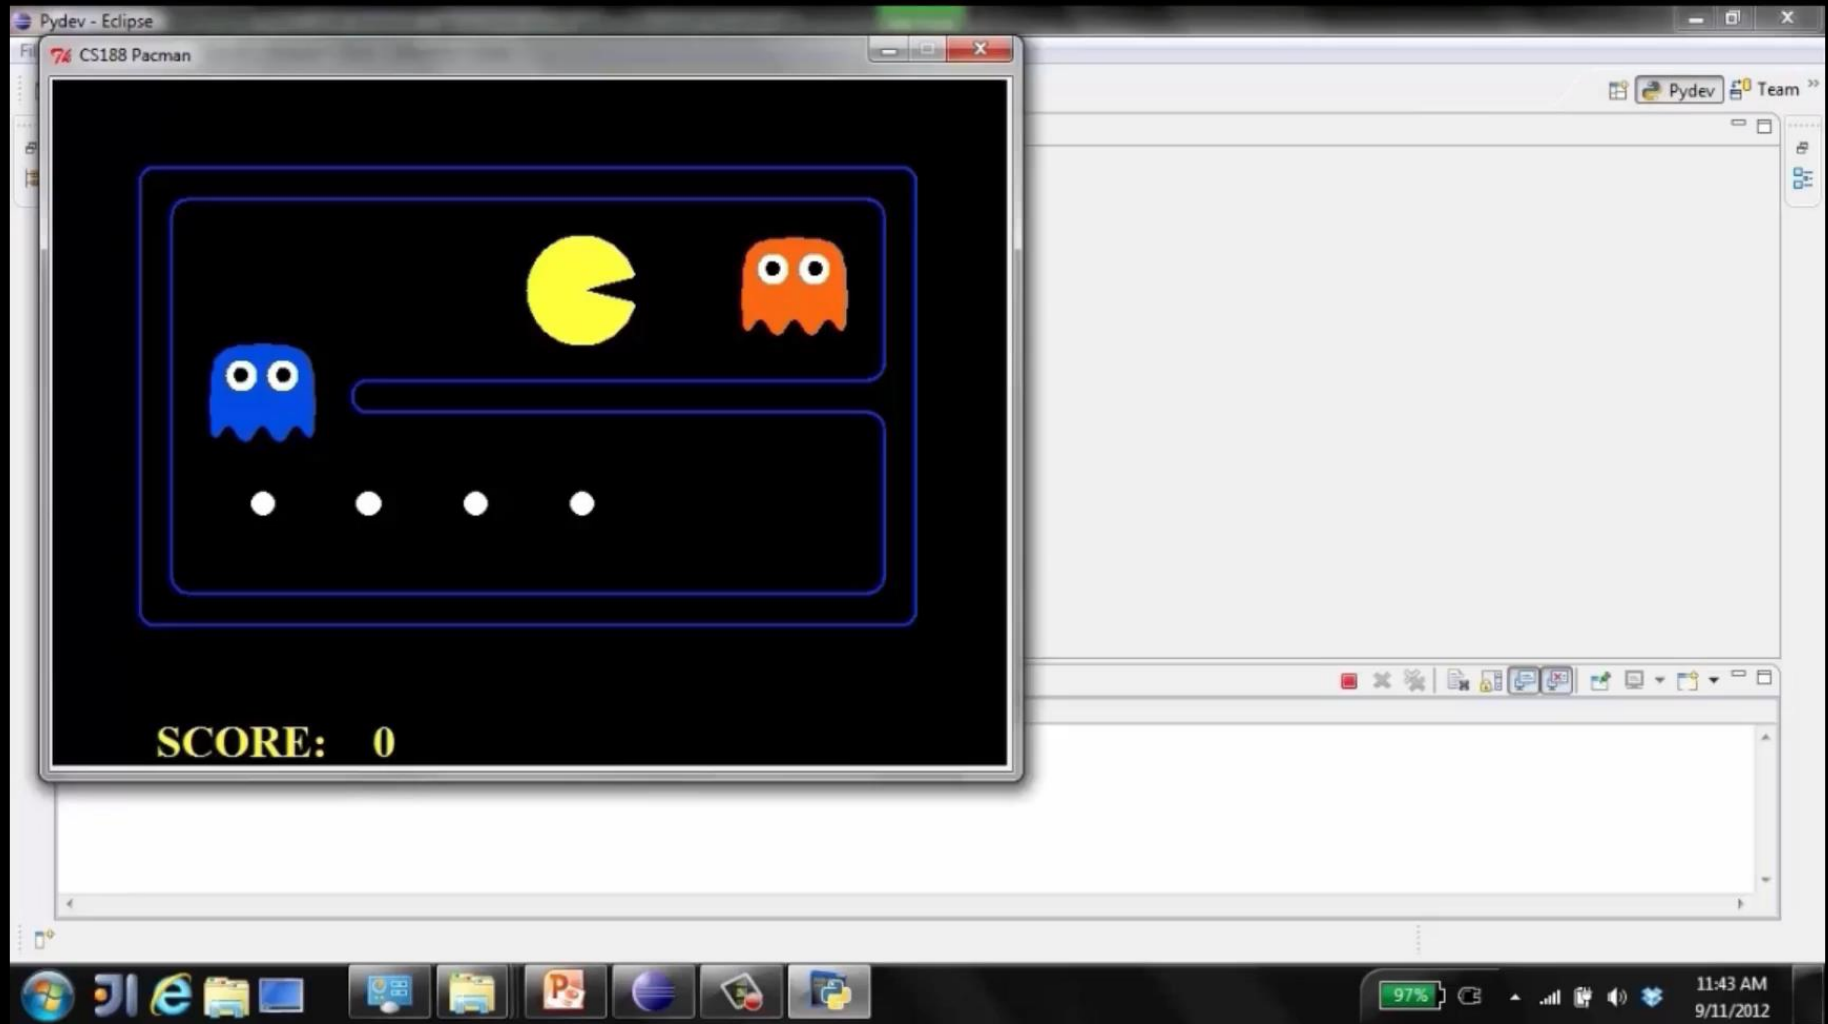


Propiedades de Minimax




Óptimo contra un jugador perfecto. **¿En otro caso?**

Video Demo Minimax: fantasmas racionales!




Eficiencia de Minimax

- ¿Cómo de eficiente es minimax?
 - Igual que (exhaustivo) **DFS**
 - Tiempo: **$O(b^m)$**
 - Espacio: **$O(b^m)$**
- Ejemplo: para ajedrez, **$b \sim 35$** , **$m \sim 100$**
 - Una solución exacta **es inviable**
 - Pero, ¿**Tenemos que explorar todos los estados?**



Podado del árbol de juego




Podado Alpha-Beta


➤ Configuración general (versión MIN)

- Estamos calculando un valor-MIN en un nodo n
- Estamos iterando sobre los hijos de n
- Al estar minimizando, el valor de n irá reduciéndose
- ¿Dónde se usa el valor de n ? MAX
- Sea a el mejor valor que MAX puede obtener a lo largo del camino actual desde la raíz
- Si n es peor que a , MAX lo evitará, por ello podemos evitar el considerar los demás hijos de n (es suficientemente malo para saber que no se hará esa jugada).

► La versión MAX es simétrica



Podado de Minimax



Implementación de Alfa-Beta

α : la mejor opción de MAX's en el camino a la raíz: inicializar con $-\infty$


β : la mejor opción de MIN's en el camino a la raíz: inicializar con $+\infty$

```
def max-value(state,  $\alpha$ ,  $\beta$ ):  
    initialize  $v = -\infty$   
    for each successor of state:  
         $v = \max(v, \text{min\_value}(\text{successor},$   
                                 $\alpha, \beta))$   
        if  $v > \beta$ :  
            return  $v$   
         $\alpha = \max(\alpha, v)$   
    return  $v$ 
```


```
def min-value(state,  $\alpha$ ,  $\beta$ ):  
    initialize  $v = +\infty$   
    for each successor of state:  
         $v = \min(v, \text{max\_value}(\text{successor},$   
                                 $\alpha, \beta))$   
        if  $v < \alpha$ :  
            return  $v$   
         $\beta = \min(\beta, v)$   
    return  $v$ 
```

Propiedades de podado Alfa-Beta


- ¡El podado no tiene efecto sobre el valor minmax calculado para la raíz!
- Una buena ordenación de los hijos mejora la efectividad del podado
- Con una “ordenación perfecta”:
 - La complejidad en tiempo se reduce a $O(b^{m/2})$



Alpha-Beta Quiz




Alpha-Beta Quiz 2



Alpha-Beta Demo


- Demo: minimax game search algorithm with alpha-beta pruning (using html5, canvas, javascript, css)
- <http://homepage.ufp.pt/jtorres/ensino/ia/alfabeta.html>

Recursos limitados

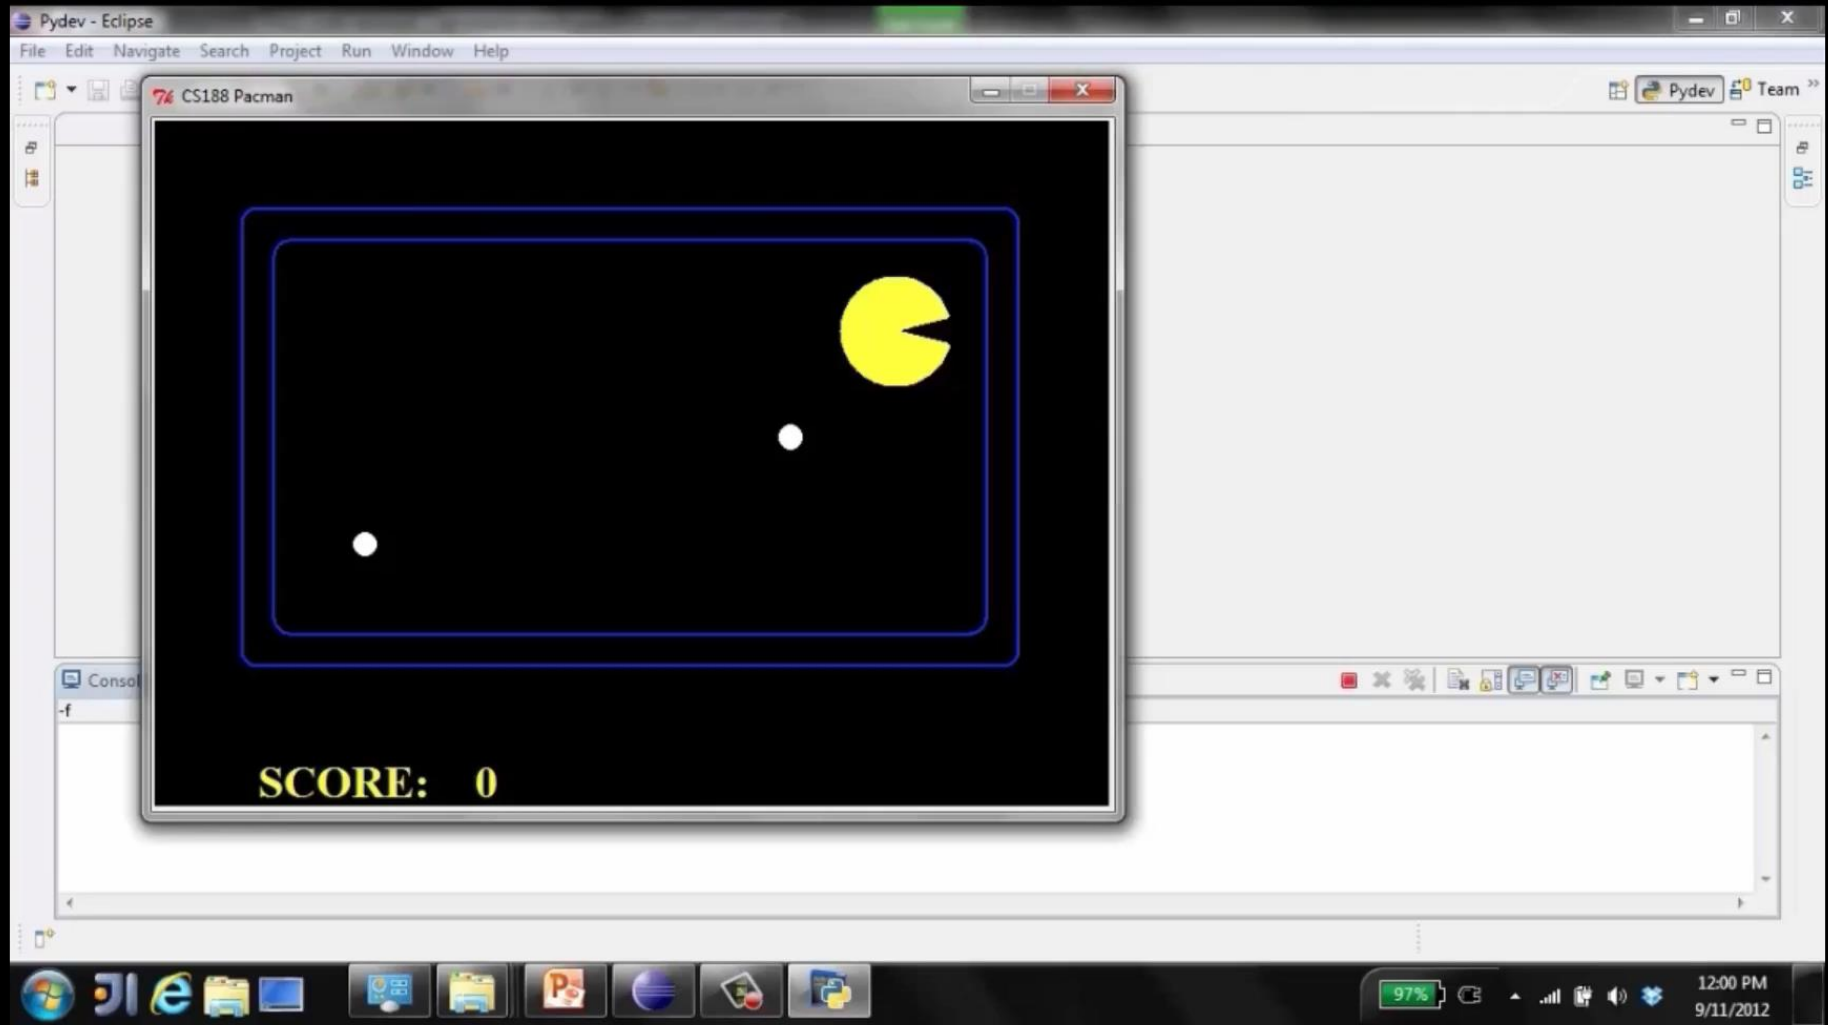


Recursos limitados


- Problema: en juegos reales, **¡no podemos buscar hasta estados terminales!**
- **Solución:** búsqueda limitada en profundidad (Depth-limited search)
 - Buscar solo una profundidad limitada del árbol
 - **Reemplazar las utilidades terminales** con una **función de evaluación** para estados no terminales
- **La garantía de juego óptimo se desvanece**



D = 2 (función de evaluación: movimientos)




¿Por qué desfallece Pacman?



➤ ¡Peligro de agentes que replanifican!

- Función de evaluación: **10 por cada punto comido**
- Pacman sabe que su puntuación aumentará yendo en las 2 direcciones comiendo un punto (west, east).
 - Pero Pacman sabe que su puntuación también subirá si hace (east, east)
 - Después de comer el punto, no hay oportunidad de anotar más puntos (en el horizonte, en este caso, 2 movimientos (profundidad))

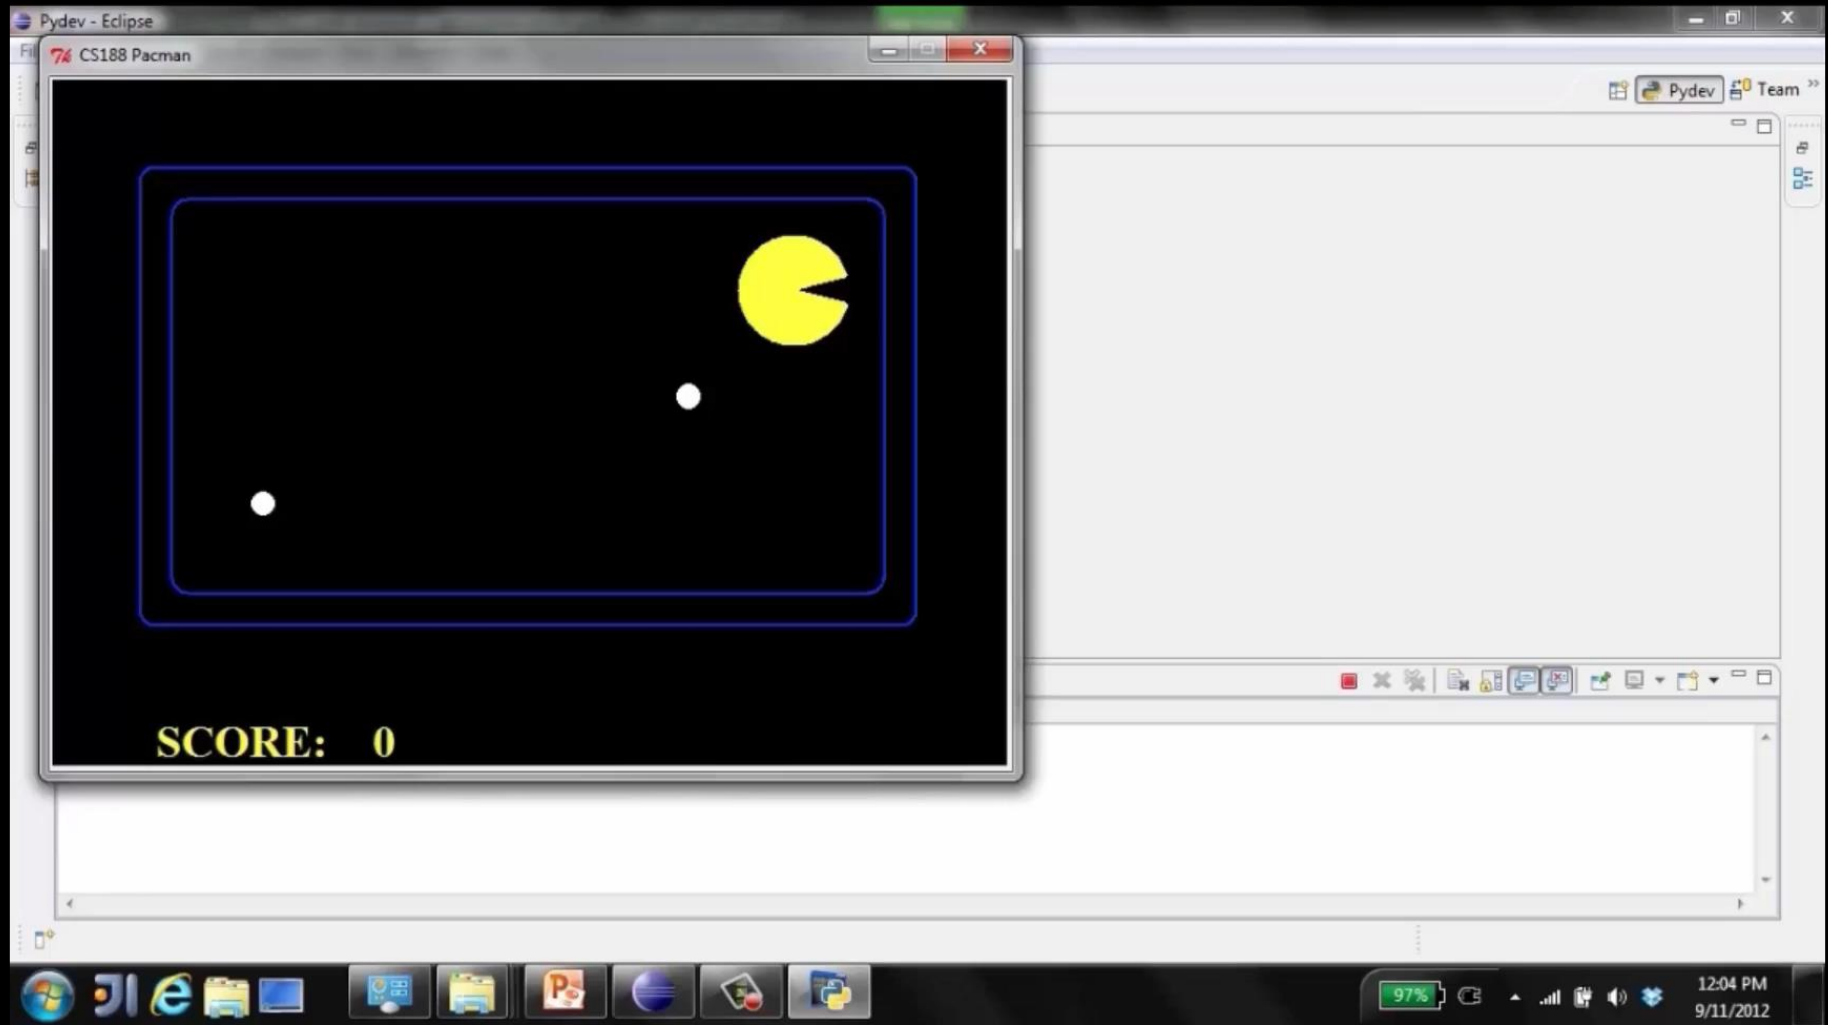
¡Pacman desfallece! ¿Mejora?



➤ ¡Peligro de agentes que replanifican!

- El problema **no era el algoritmo!** sino la **función de evaluación!**
- **Nueva función de evaluación:** 10 por cada punto comido + **1 por cercanía** al siguiente punto

D = 10 (función de evaluación: movimientos + cercanía)




Funciones de evaluación



Funciones de evaluación

- Las funciones de evaluación puntúan estados no terminales, con búsqueda de profundidad limitada



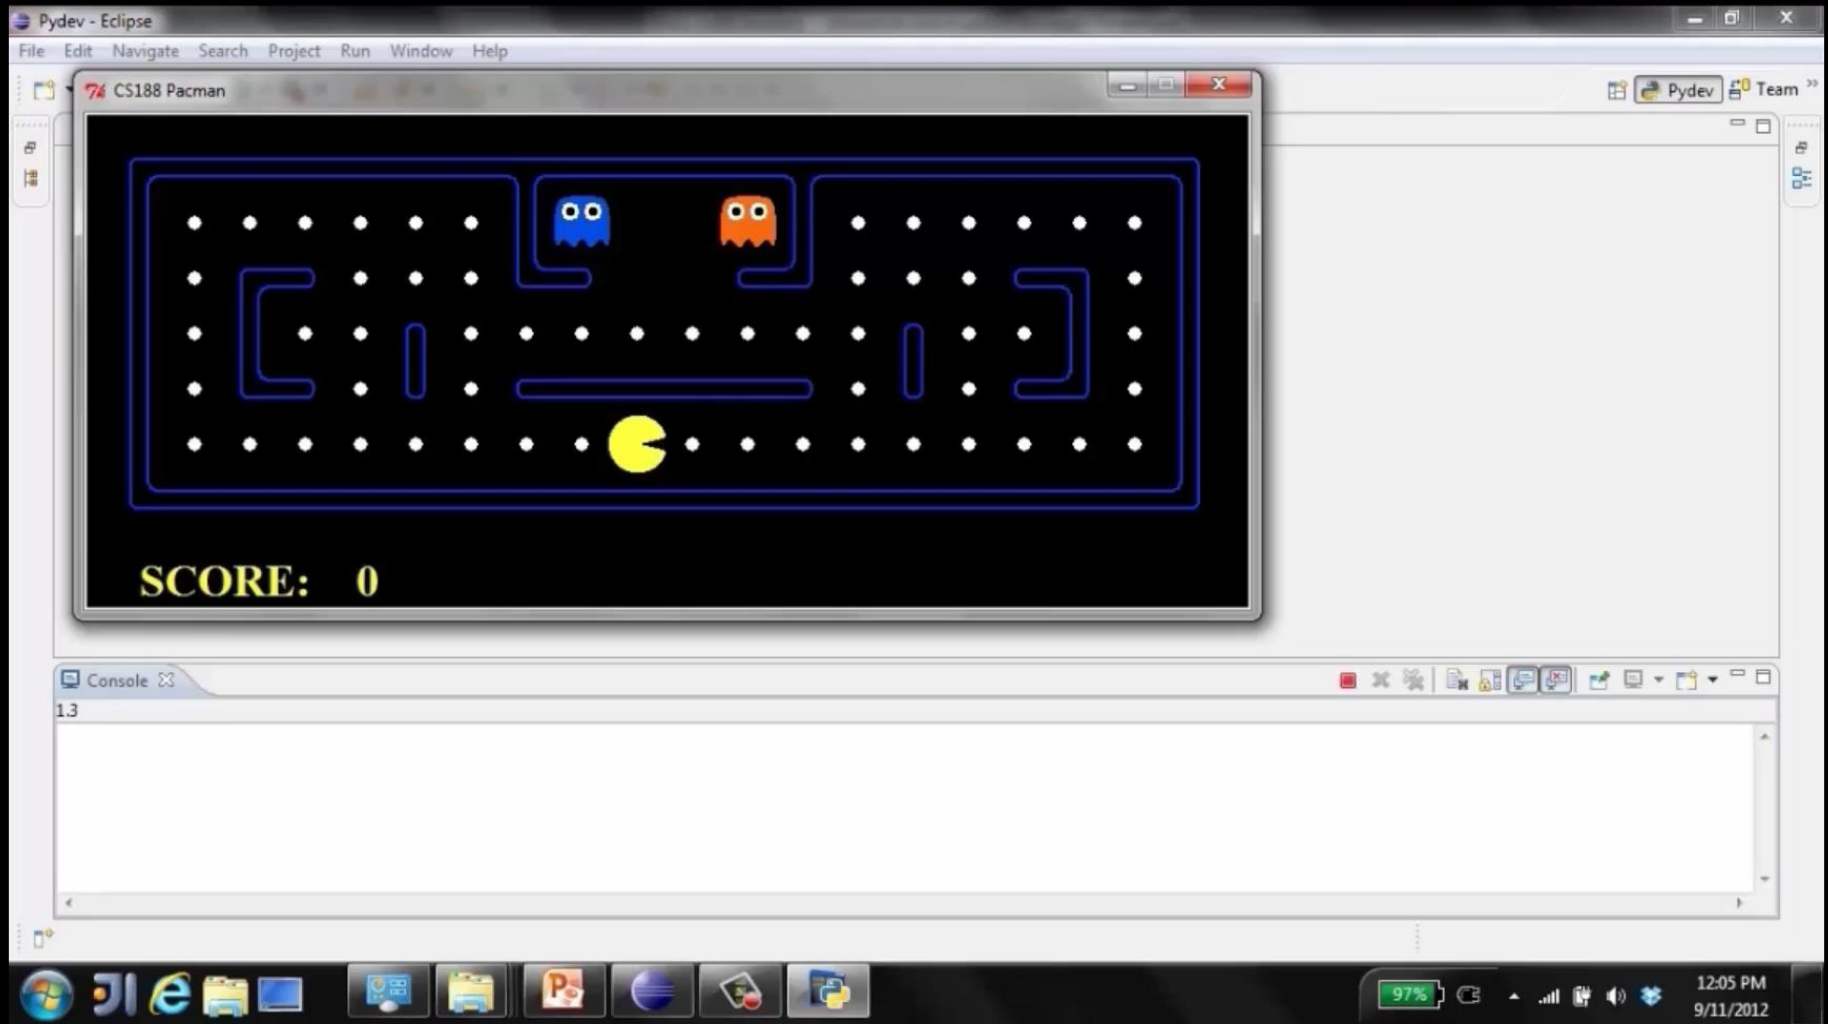
- **Función ideal:** devuelve el valor real de minimax en esa posición hasta estado terminal
- **En la práctica:** normalmente suma lineal ponderada de características (features)

$$\text{Eval}(s) = w_1 * f_1(s) + w_2 * f_2(s) + \dots + w_n * f_n(s)$$


- Por ejemplo:

$f_1(s)$ = (cantidad de reina blancas – cantidad reina negras), etc.

Vídeo Demo Fantasma inteligentes (Coordinación)




MiniMax (coordinado)

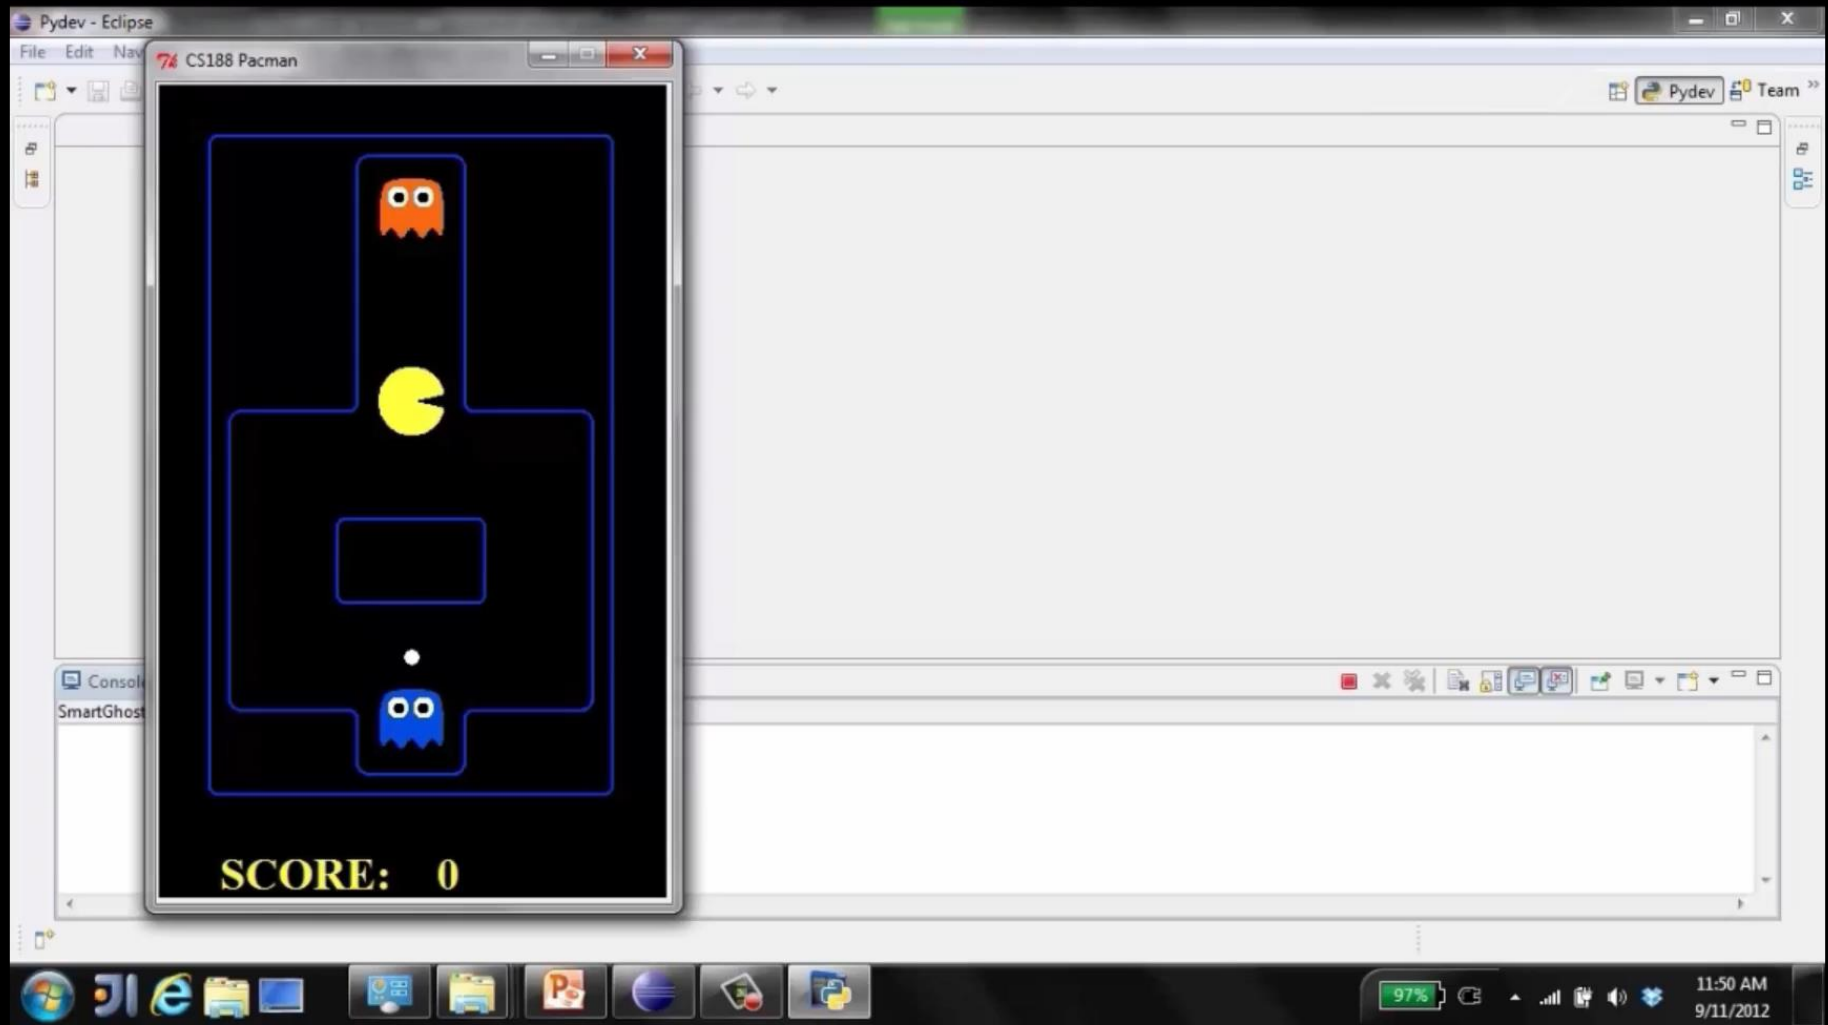


La profundidad es importante

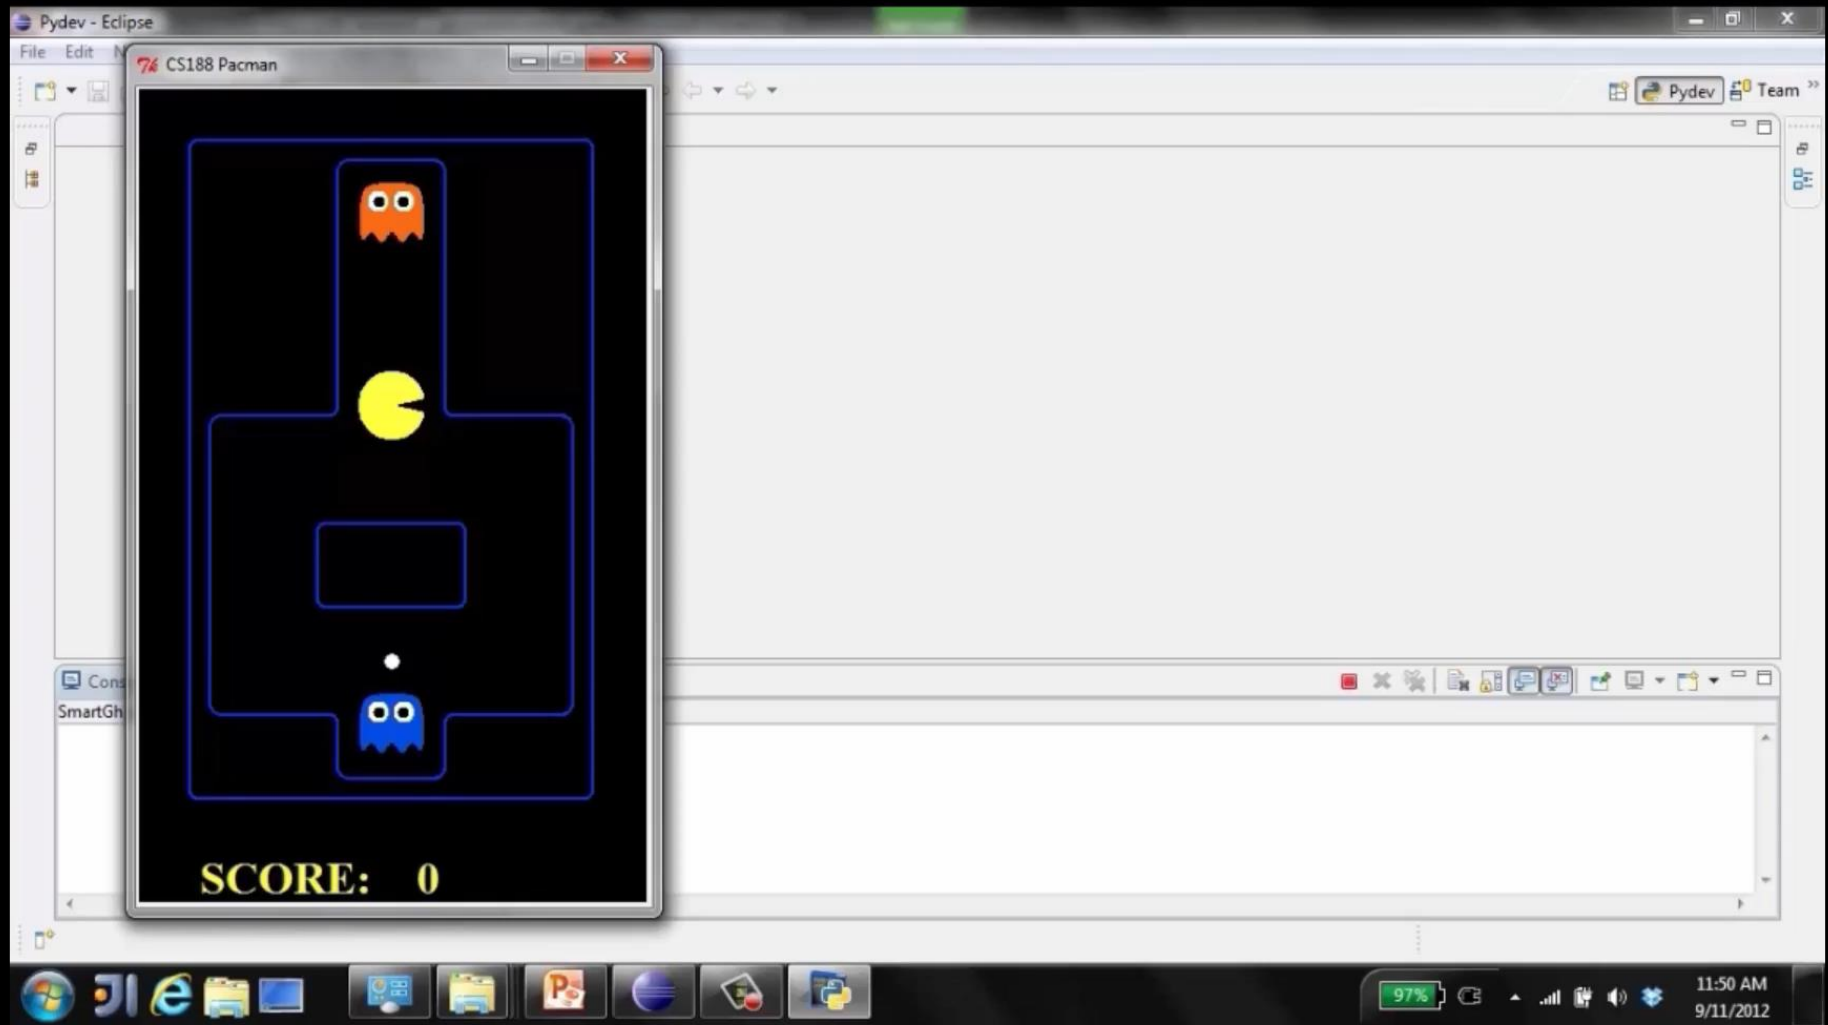
- Las **funciones de evaluación son** siempre **imperfectas**
- Cuando **más profundamente en el árbol probemos la función de evaluación**, es menos importante la calidad de la función de evaluación




Vídeo Demo Profundidad limitada (d=2)





Vídeo Demo Profundidad limitada (10)



Resultados inciertos: juegos estocásticos




Caso peor vs. caso medio



Idea: los resultados inciertos están controlados por el azar, no por el adversario!

Búsqueda Expectimax

- ¿Por qué podemos no conocer el resultado de una acción?
 - **Aleatoriedad** explícita: **echar los dados**
 - **Oponentes impredecibles**: los fantasmas responden aleatoriamente
 - **Las acciones pueden fallar**: al mover un robot, **las ruedas pueden patinar**
- **Búsqueda expectimax**: calcular la puntuación media con un juego óptimo
 - Estados MAX como en búsqueda minimax
 - Los estados aleatorios son como los estados MIN pero el resultado es incierto
 - Se calcularán las utilidades esperadas
 - Por ej: Tomar la media ponderada de los hijos (expectativa)



Pseudocódigo de Expectimax

```
def value(state):
```

```
    if the state is a terminal state: return the state's utility
```

```
    if the next agent is MAX: return max-value(state)
```

```
    if the next agent is EXP: return exp-value(state)
```

```
def max-value(state):
```

```
    initialize  $v = -\infty$ 
```

```
    for each successor of state:
```

```
         $v = \max(v,$   
            value(successor))
```

```
    return v
```

```
def exp-value(state):
```

```
    initialize  $v = 0$ 
```

```
    for each successor of state:
```


```
         $p = \text{probability}(\text{successor})$ 
```

```
         $v += p * \text{value}(\text{successor})$ 
```

```
    return v
```

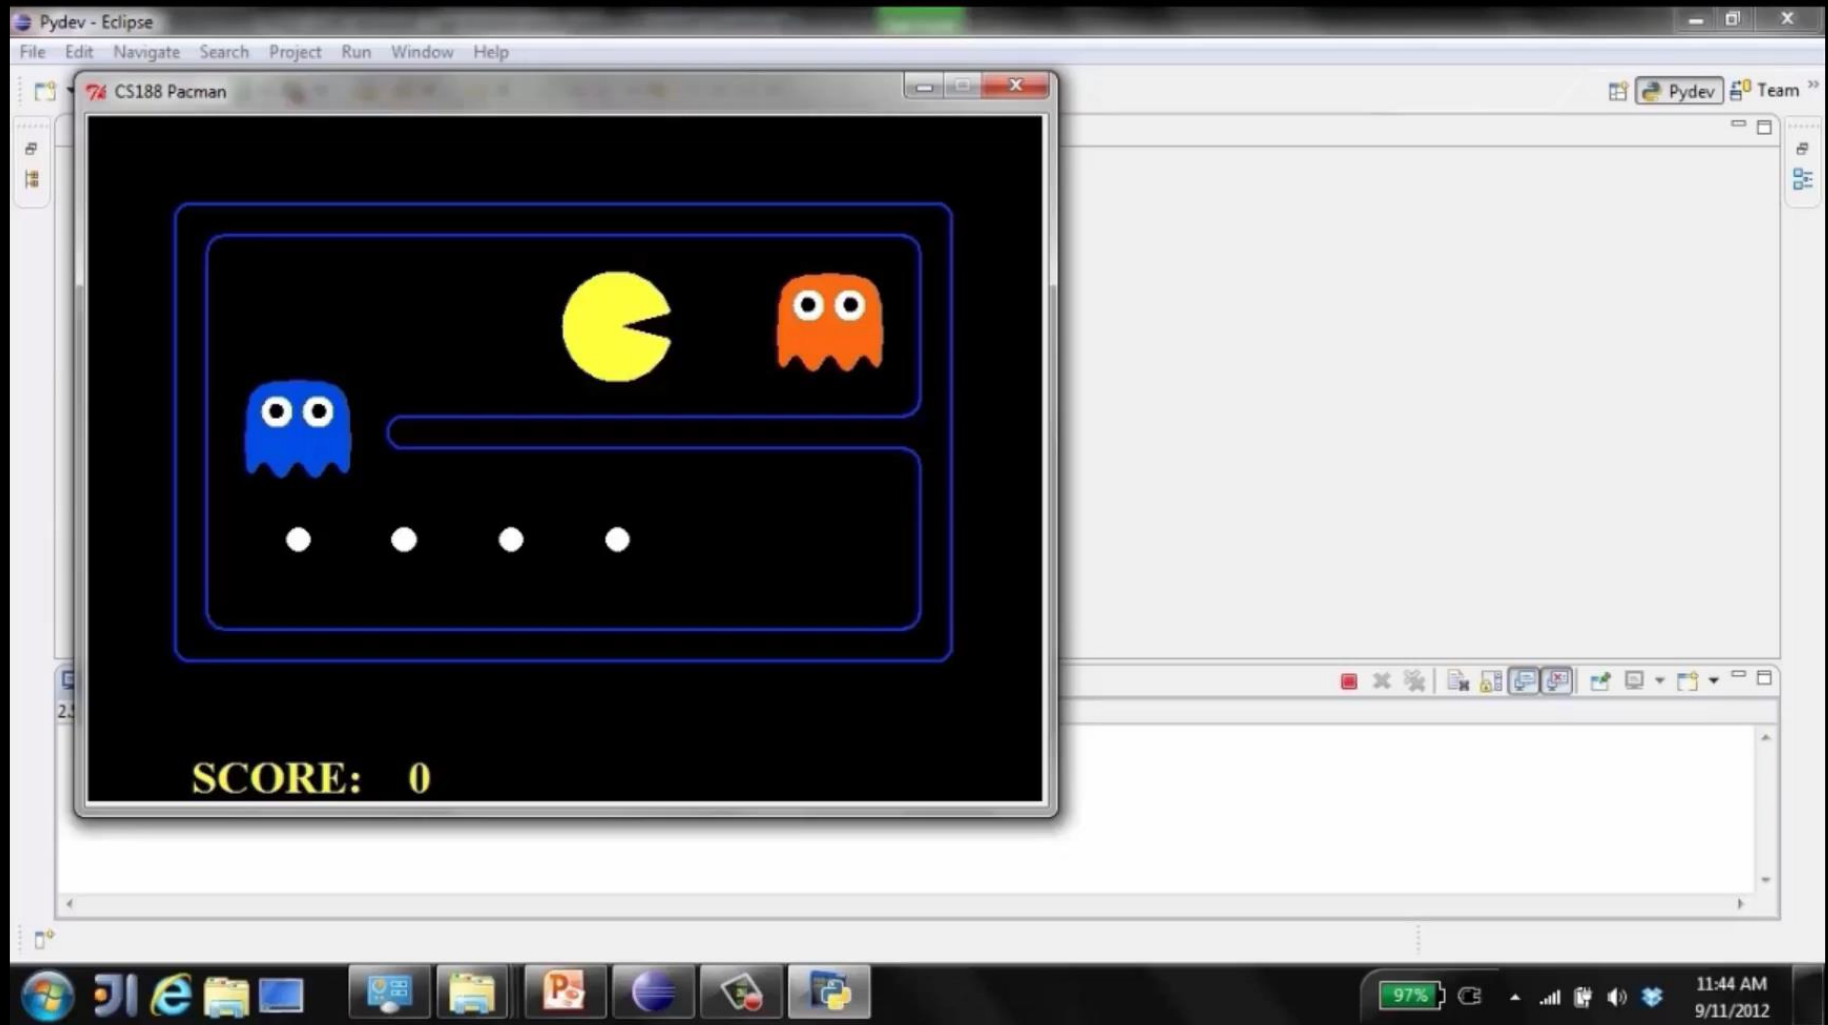
Pseudocódigo de Expectimax

```
def exp-value(state):  
    initialize v = 0  
    for each successor of state:  
        p = probability(successor)  
        v += p * value(successor)  
    return v
```





$$v = (1/2)*(8) + (1/3)*(24) + (1/6)*(-12) = 10$$

Vídeo Demo Expectimax (fantasmas aleatorios)

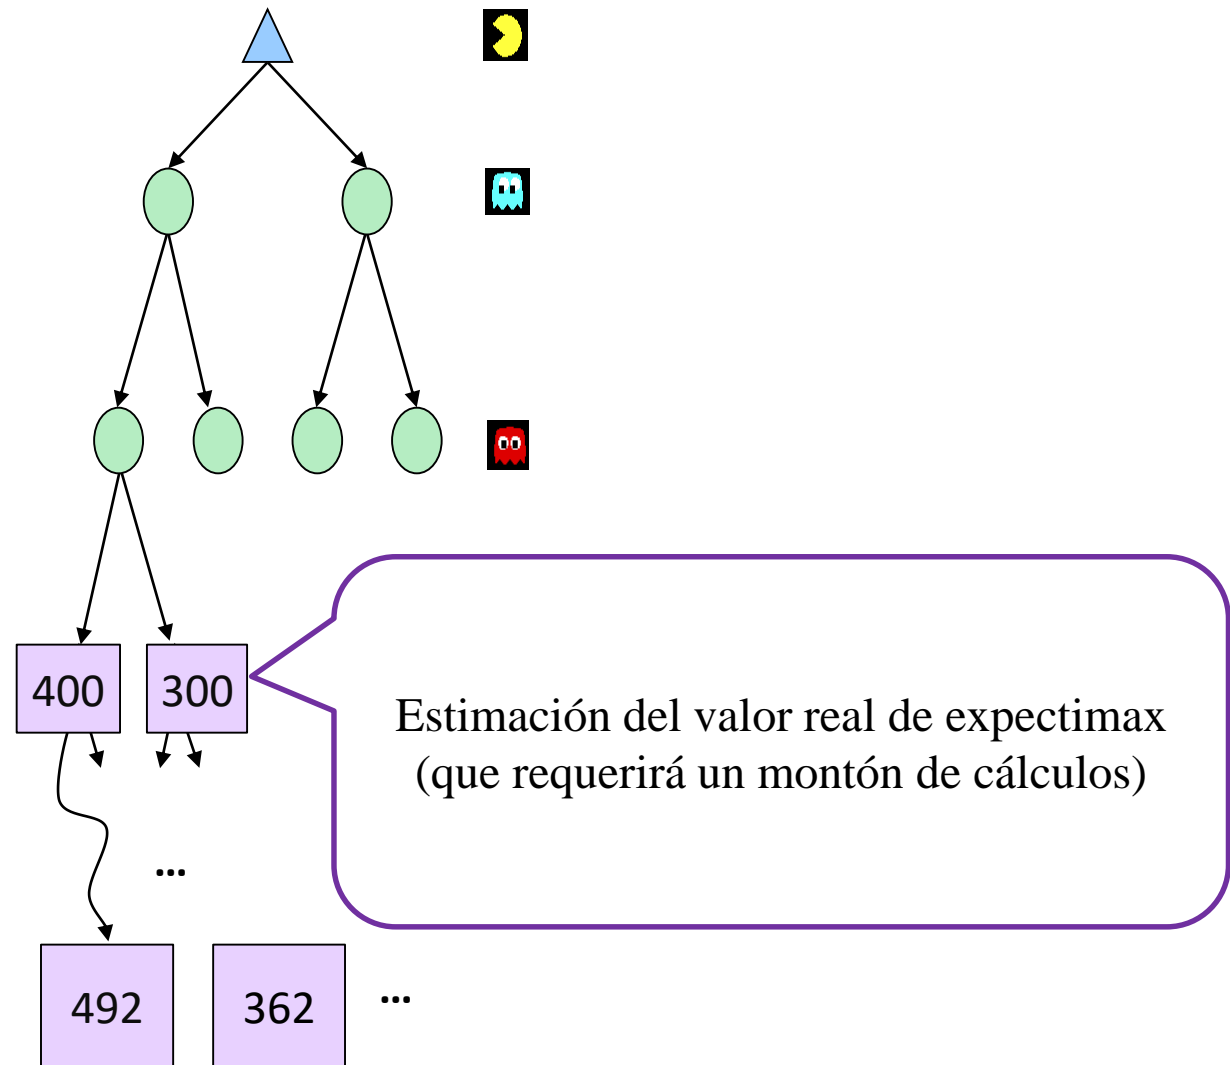


¿Poda de Expectimax?



No se puede podar! Ya que se debe analizar todos los hijos!

Expectimax con profundidad limitada



Probabilidades



Recuerdo: Probabilidades




- Una **variable aleatoria (random)** representa un evento cuyo resultado es desconocido
- Una **distribución de probabilidad** es una asignación de pesos a resultados

- Ejemplo: **Tráfico en la autovía**

- **Variable aleatoria:** T = hay tráfico o no
- **Valores:** T en {nada, ligero, mucho}
- **Distribución:** $P(T=\text{nada}) = 0.25$, $P(T=\text{ligero}) = 0.50$, $P(T=\text{mucho}) = 0.25$


- Algunas leyes de probabilidad:

- Las probabilidades **son siempre no negativas**
- **La suma** de probabilidades sobre todos los valores posibles **suma uno**





Recuerdo: Expectativas

- El valor esperado de una función de una variable aleatoria es la media ponderada por la distribución de probabilidad de los resultados
- Ejemplo: ¿Cuánto tardaré en llegar al aeropuerto?




$$\begin{array}{rccccccc} \text{Tiempo:} & 20 \text{ min} & & 30 \text{ min} & & 60 \text{ min} & & \\ & \times & & \times & & \times & & \\ \text{Probabilidad:} & 0.25 & + & 0.50 & + & 0.25 & \rightarrow & 35 \text{ min} \end{array}$$



¿Qué probabilidades usamos?

- En la búsqueda expectimax, tenemos un modelo probabilístico de cómo el oponente (o entorno) se comportará en cualquier estado:
 - El modelo podría ser **una distribución uniforme (echar los dados)**
 - El modelo podría ser **sofisticado y requerir un montón de computación**
 - Tendremos un nodo aleatorio por cada situación fuera de nuestro control: **oponente o entorno**
 - ¡El modelo podría decir qué acciones adversarias son probables!
- Por ahora, asumiremos que cada nodo **viene mágicamente con probabilidades** que especifican la distribución respecto a sus valores




¡Tener una suposición probabilística sobre la acción de otro agente no quiere decir que ese agente esté echando una moneda!

Quiz: Probabilidades informadas


- Supongamos que nuestro oponente está ejecutando un minimax de profundidad 2, usando ese resultado un 80% de las veces, y moviéndose aleatoriamente en otro caso
- Pregunta: ¿Qué tipo de búsqueda en árbol usaríamos?

➤ Respuesta: **¡Expectimax!**

- Para estimar las probabilidades de CADA nodo aleatorio, tendríamos que ejecutar una simulación de nuestro oponente
- Esto nos puede llevar rápidamente a ineficiencia (tiempo)
- Peor si tenemos que simular a nuestro oponente simulándonos a nosotros ...




Modelando asunciones



Los peligros del optimismo y el pesimismo

Optimismo peligroso

Asumiendo azar cuando el mundo es adversarial




Pesimismo peligroso

Asumiendo el caso peor cuando es poco probable



Asunciones vs Realidad



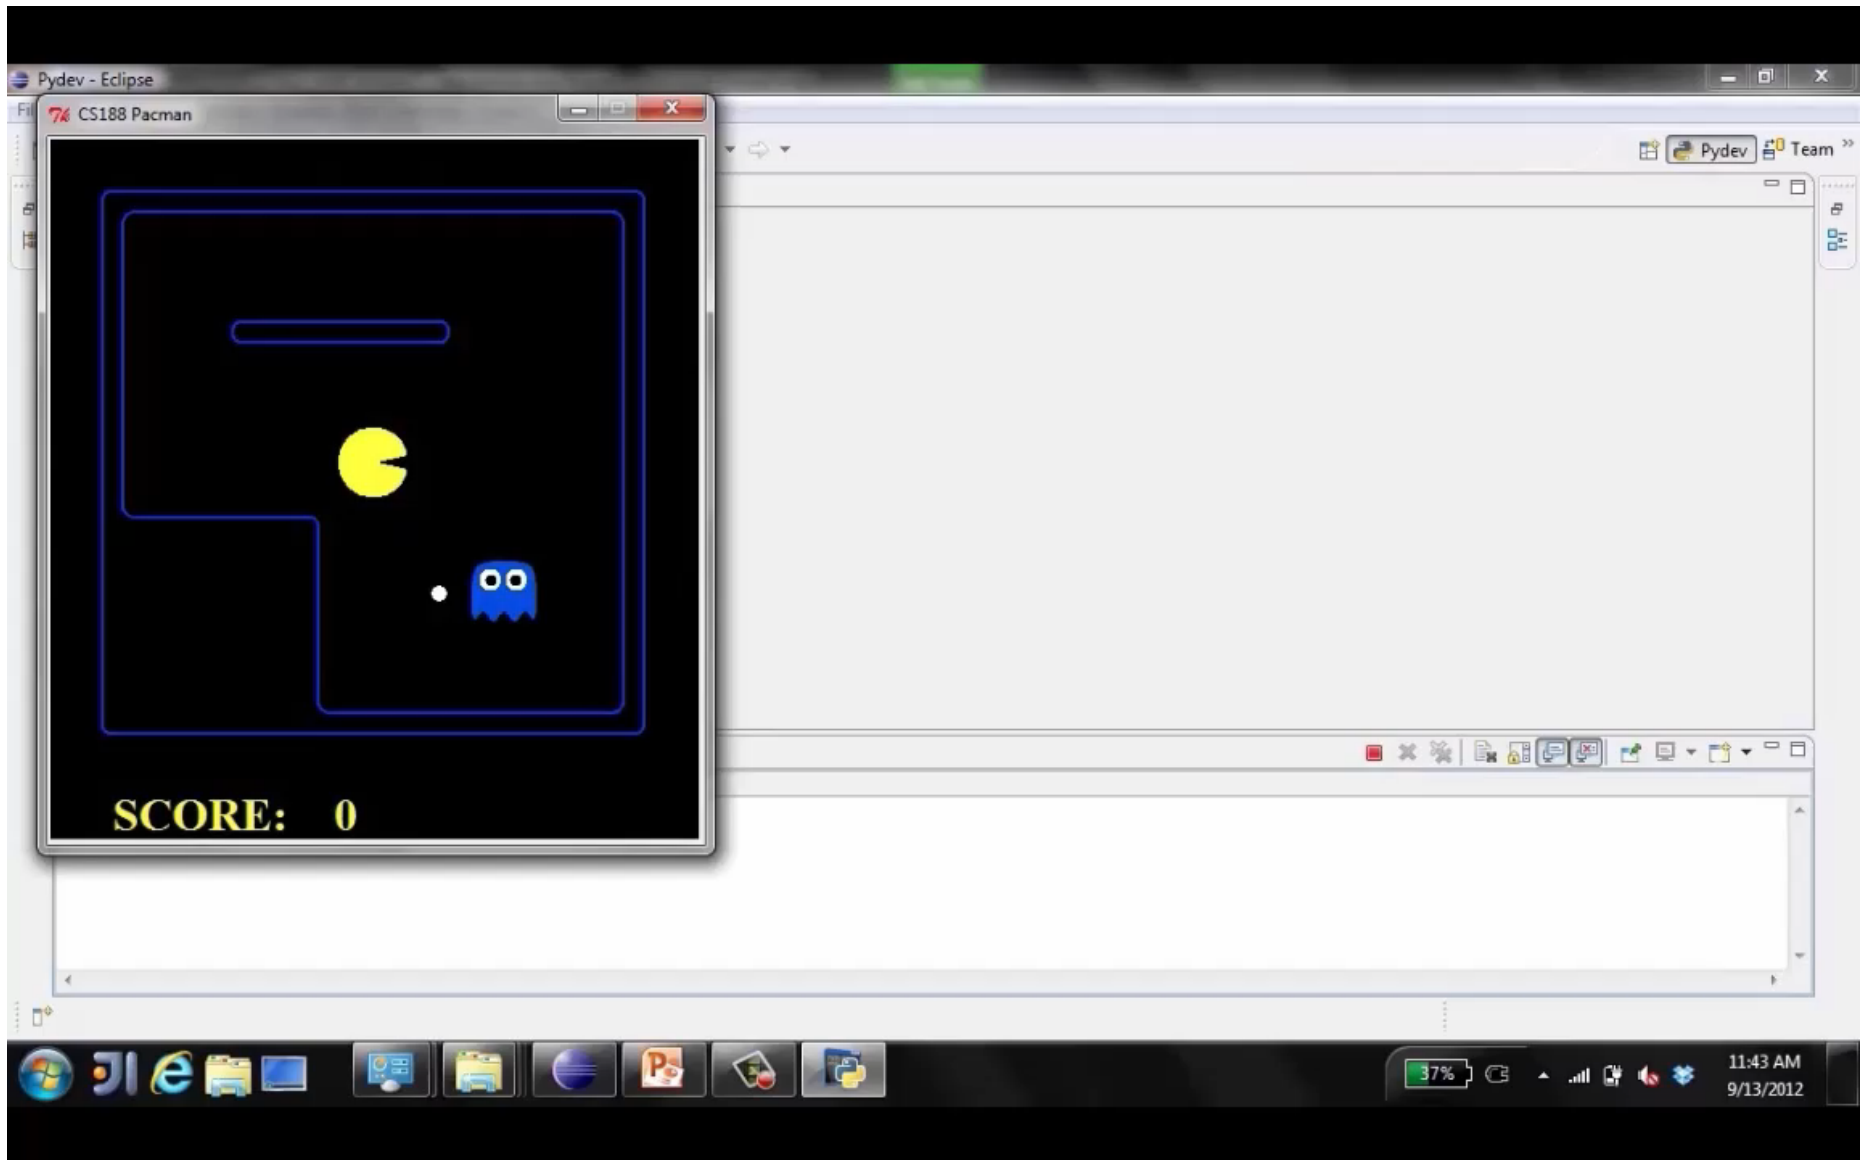
	Fantasma Adversarial	Fantasma Aleatorio
Minimax Pacman	Won 5/5 Avg. Score: 483	Won 5/5 Avg. Score: 493
Expectimax Pacman	Won 1/5 Avg. Score: -303	Won 5/5 Avg. Score: 503

Resultados jugando 5 partidas

- Pacman usa búsqueda de profundidad 4 con una función de evaluación que evita el fantasma
- El fantasma usa búsqueda de profundidad 2 con una función de evaluación que busca a Pacman

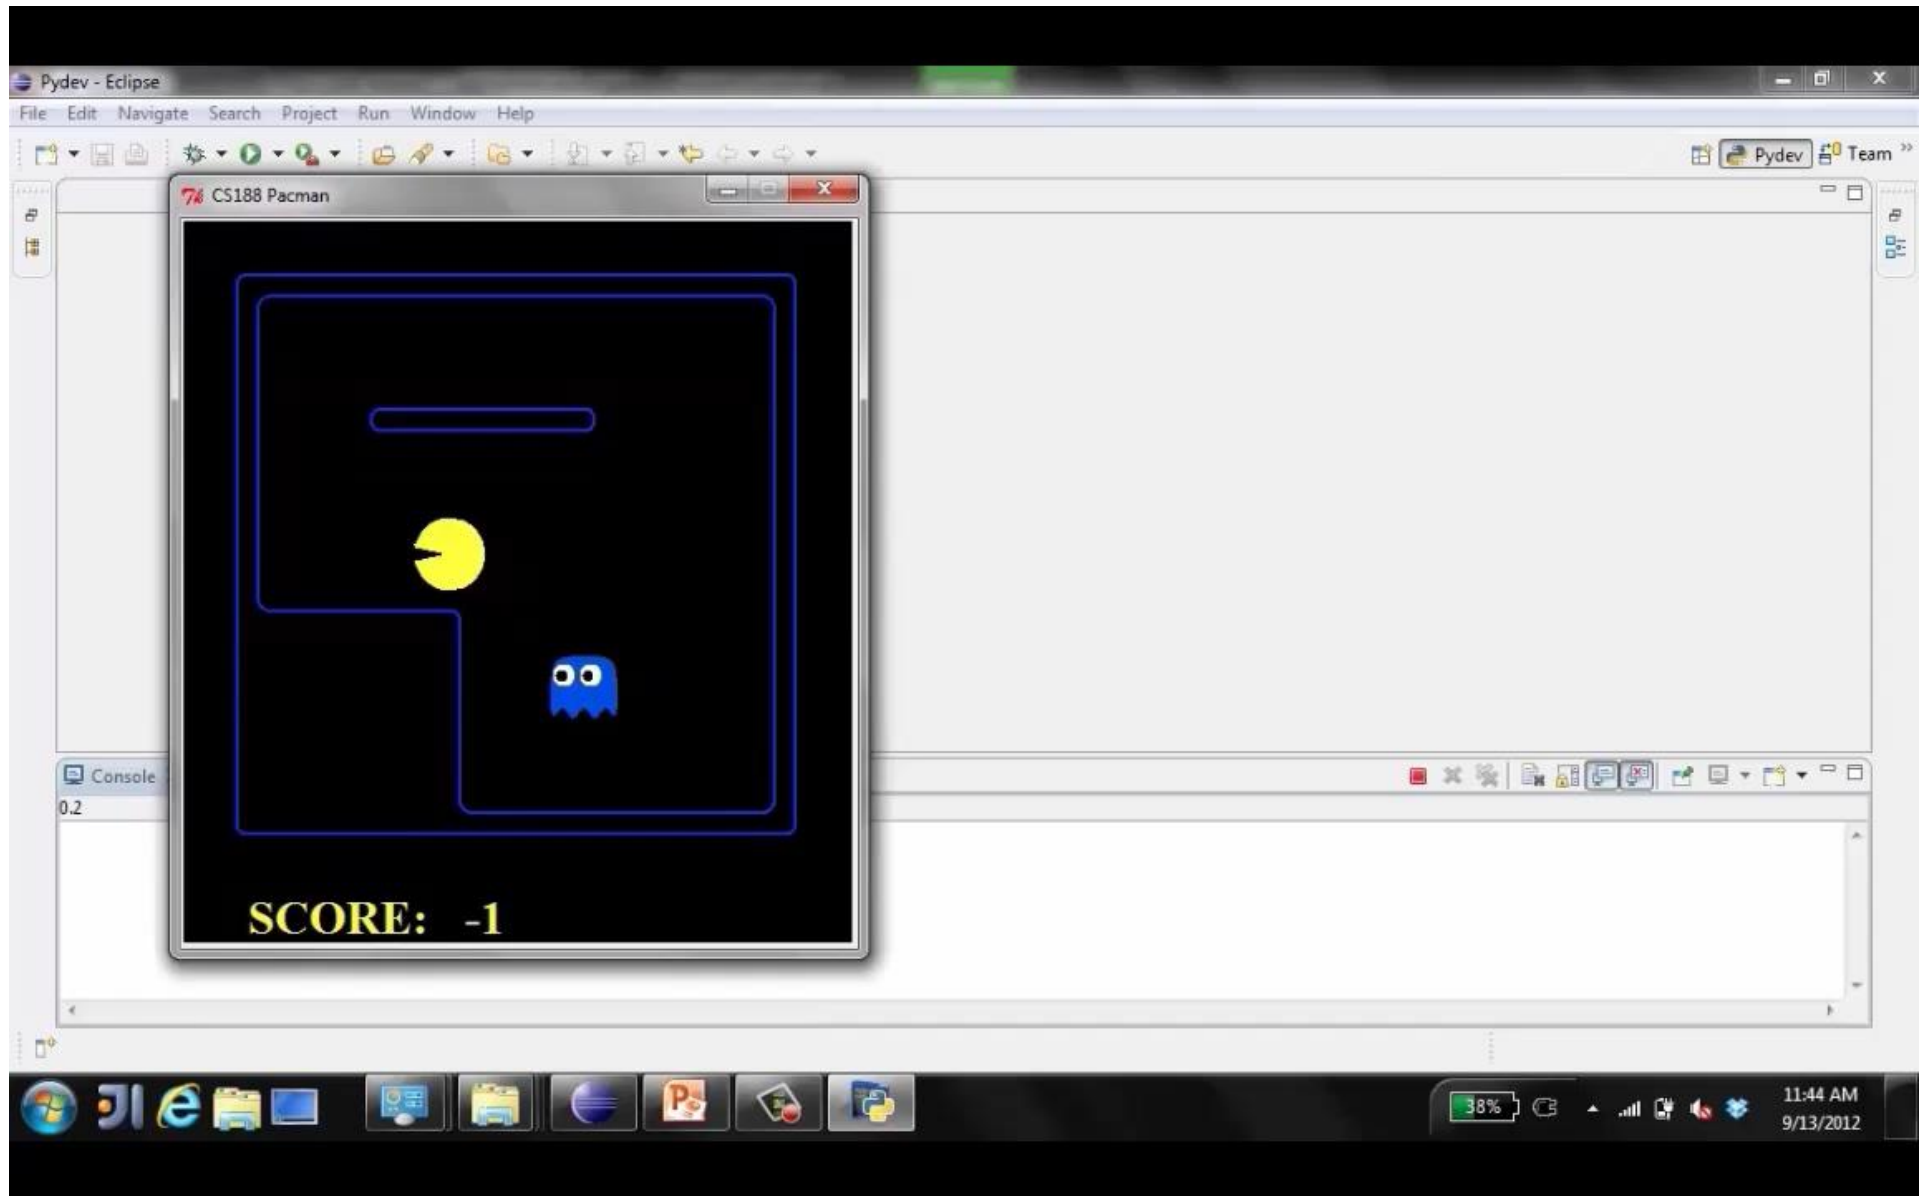
Vídeo demo asunciones sobre el mundo

Fantasma aleatorio – Pacman Expectimax



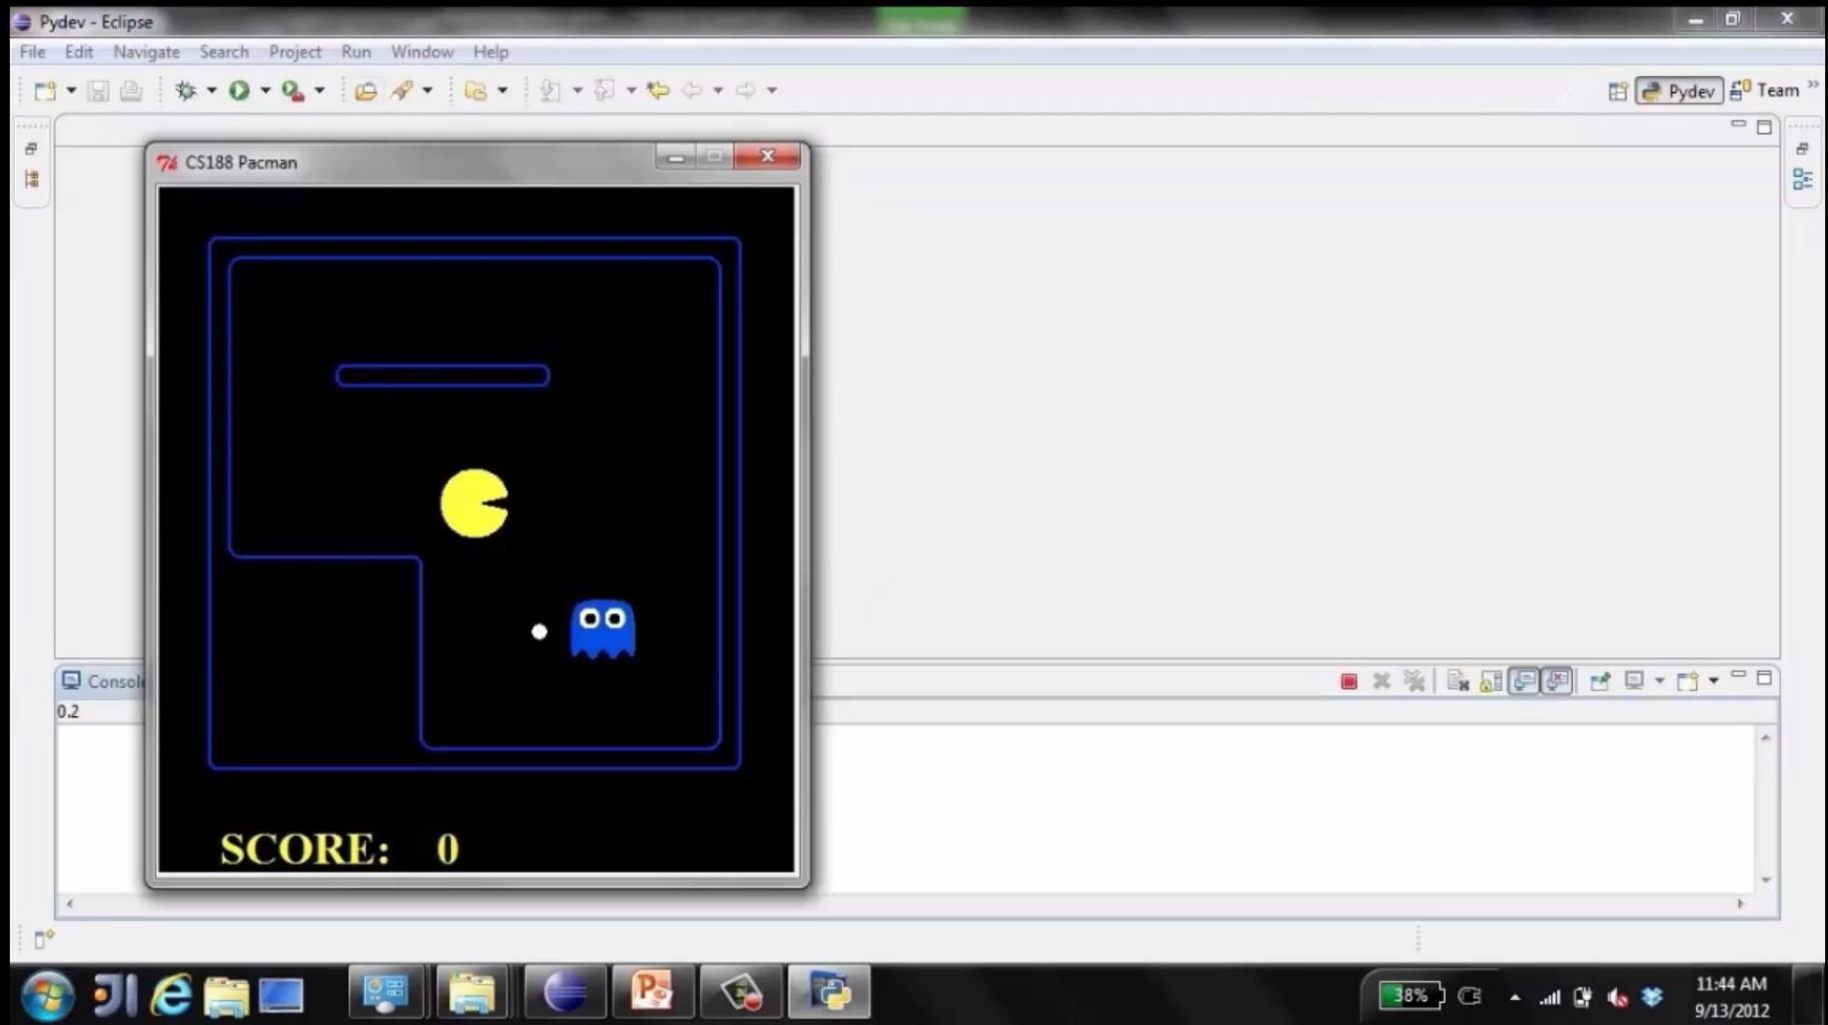
Vídeo demo asunciones sobre el mundo

Fantasma aleatorio – Pacman Minimax



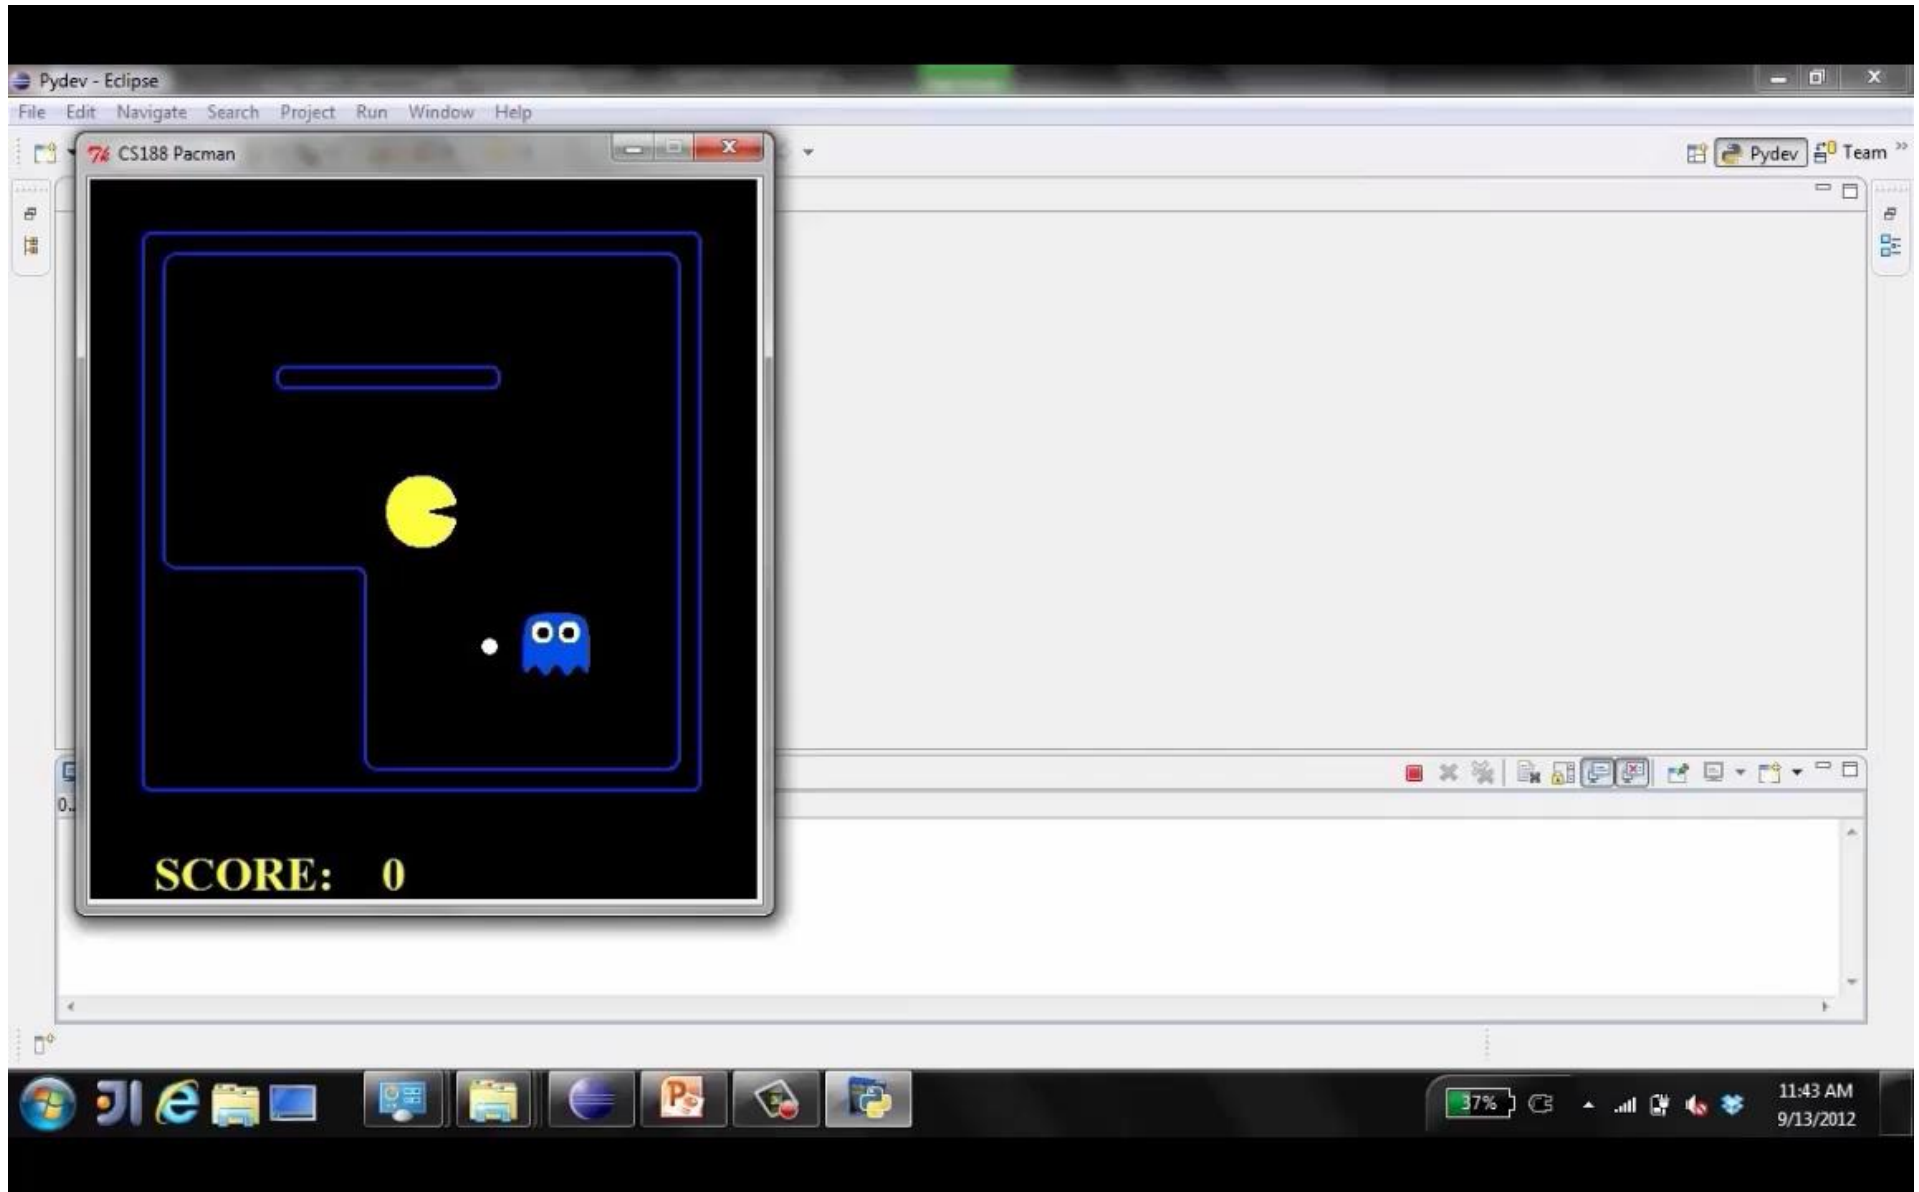
Vídeo demo asunciones sobre el mundo

Fantasma adversarial – Pacman Expectimax




Vídeo demo asunciones sobre el mundo


Fantasma adversarial – Pacman Minimax




Ejercicios: MiniMax y $\alpha - \beta$



Solución: MiniMax




Solución: $\alpha - \beta$




- Teniendo en cuenta tu elección ... y que el oponente utiliza la misma función de evaluación (heurístico), cual sería el movimiento que haría el oponente?

Solución: $\alpha - \beta$



Ejercicios: MiniMax con 3 jugadores?



Solución: MiniMax con 3 jugadores

